

T.C.
ONDOKUZ MAYIS ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



Bitirme Projesi – Rapor 2
Müge Tetik 20060343
Ahmet Güneş 19060387
Mehmet Batuhan Topal 20060405
25/12/2023

ENSEMBLE LEARNING

Ensemble learning, makine öğrenimi alanında sıklıkla başvurulan gelişmiş bir teknik olarak göze çarpıyor. Bu yöntem, tek bir öğrenme algoritmasının sınırlamalarını aşmak amacıyla bir araya getirilen çok sayıda öğrenme algoritmasını içeren bir model oluşturma yaklaşımını benimser. Temel hedefi, modelin gücünü artırmak, genelleme yeteneğini geliştirmek ve daha istikrarlı sonuçlar elde etmektir.

Dong ve diğerleri [1] topluluk öğrenmesi üzerine yapılan çalışmaları incelemiştir. Bu çalışma, denetimli öğrenme alanında yapılan birçok araştırmayı gözden geçirmiştir. Veri eğitimindeki ve dönen sonuçlardaki; dengesizlik (imbalanced), yüksek boyut (high-dimensional) ve gürültü (noisy) gibi karmaşık veri (data complexity) sorunlarına çözüm aranmıştır.




Figure 1 Öğrenme eğrisi ile model karmaşıklığı arasındaki ilişki

Figure 1'deki gibi (Fortmann-Roe S. tarafından yazılan "Understanding the Bias-Variance Tradeoff" başlıklı makalenin Şekil 6 bölümünden alınmıştır) öğrenme modelinin toplam hatasının dibe ulaşana kadar sürekli olarak azaldığını, ardından model karmaşıklığı arttığında hızlı bir yükseliş eğilimi gösterdiğini gözlemliyoruz.

Ensemble learning'in temel prensibi, farklı öğrenme modellerinin farklı güçlü yönleri olabileceği ve bu modellerin bir araya getirildiğinde daha etkili bir performans elde edilebileceğidir. Bu strateji, tek bir modelin başarı sınırlarını aşmak ve karmaşık veri yapıları üzerinde etkili bir şekilde çalışmak için çeşitli öğrenme algoritmalarını birleştirme amacını taşır. Ayrıca, overfitting gibi aşırı uyum problemlerine karşı direnç gösterme eğilimindedir ve genellikle daha genelleme yeteneği yüksek bir model oluşturabilir.

Ensemble learning'i bir futbol takımına benzetebiliriz. Her oyuncunun farklı yeteneklere sahip olduğu gibi, farklı öğrenme modelleri de birbirini tamamlayacak şekilde bir araya gelir. Bu sayede, her bir modelin zayıf olduğu noktalarda diğer modeller destek sağlar. Bu strateji, çok spesifik durumlarla başa çıkabilen bir model oluşturarak, veriye daha iyi adapte olma yeteneğiyle de bilinir. Yani, her bir öğrenme modeli bir tür uzmanlık alanına sahip olabilir, bir araya geldiklerinde ise çok daha güçlü bir ekip oluşturabilirler. Ensemble learning, birbirini tamamlayan modelleri

birleştirerek daha sağlam ve güvenilir bir tahmin yapma yeteneği sağlayarak, çeşitli veri setleri üzerinde daha etkili bir performans sergileyebilir.

Zhiwen ve diğerlerine [2] göre, mevcut topluluk öğrenme yöntemleri dört kategoride gruplandırılabilir: denetimli topluluk sınıflandırması (supervised ensemble classification), yarı denetimli topluluk sınıflandırması (semi-supervised ensemble classification), kümeleme topluluğu (clustering ensemble) ve yarı denetimli kümeleme topluluğu (semi-supervised clustering ensemble).

Supervised ensemble classification:

Figure 2’de (Zhiwen YU , Xibin DONG, Wenming CAO, Yifan SHI, Qianli MA, “A survey on ensemble learning“ 3. sayfa) ensemble learning modelinin iki adımdan oluşan ana fikrini göstermektedir.

- 1- Birden fazla zayıf model kullanarak daha iyi sonuç üretmeyi hedeflemek.
- 2- Bir tutarlılık fonksiyonu üzerinden sonuç beklemek.

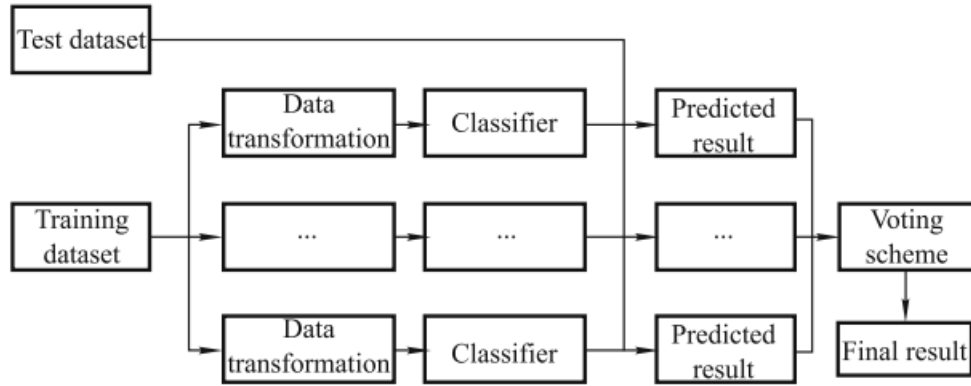


Figure 2 Topluluk sınıflandırmasının (Ensemble Learning) framework'ü

Yaygın olarak kullanılan topluluk sınıflandırma (ensemble classification) yöntemleri arasında bagging, AdaBoost , random forest, random subspace, gradient boosting bulunmaktadır. Bagging [3], eğitim veri setinden rastgele örnekleme yaparak alt küme oluşturur ve bu alt kümeleri entegre etmek için temel modellerin eğitiminde kullanır. Bu yöntemde, temel modellerin eğitimi paralel olarak gerçekleştirilir.

AdaBoost [4], örneklerin ağırlıklarını yineleyici bir şekilde ayarlayarak yanlış sınıflandırılan örnekler odaklanır, bu sayede temel modellerin sınıflandırma performansını nihai entegrasyon için iyileştirir. AdaBoost'ta temel modellerin eğitimi paralel değil, tandem bir şekilde gerçekleştirilir.

Random Forest [5], çeşitli perspektiflerden çoklu karar ağacı modellerini eğitir: örnek boyutu ve özellik boyutu. Bu sayede, birden fazla karar ağacının aşırı uyum eğilimini hafifletmek adına karar ağaçlarının oylama sonuçlarını entegre eder. Random Forest'taki temel modellerin eğitimi, bagging yöntemine benzer şekilde paralel olarak gerçekleşir.

Random Subspace [6], Random Forest'a benzer şekilde çalışır, ancak temel fark, her bir temel modelin eğitiminde özelliklerin rastgele seçilmiş bir alt kümesinin kullanılmasıdır. Random Subspace'in temel amacı, her bir temel modelin farklı özellikleri öğrenmesini sağlayarak, özellikler arasındaki ilişkileri inceleyerek ve veri setindeki gürültüye karşı direnç göstererek genel model performansını artırmaktır. Bu yöntem, yüksek boyutlu veri setlerinde etkili bir şekilde çalışabilir ve ensemble learning prensiplerini kullanarak daha güçlü ve genelleştirilebilir modeller oluşturabilir.

Gradient Boosting [7], ensemble learning'in bir formu olup, zayıf öğrencilerin (learner) güçlü bir tahmin modeline dönüştürülmesini hedefler. İlk aşamada basit bir model ile başlar ve ardından bu modelin hatalarını düzeltmeye odaklanarak sırasıyla yeni modeller ekler. Her model, önceki modellerin hata yaptığı noktalara odaklanarak geliştirilir. Bu adımlar, belirli bir iterasyon sayısına veya belirli bir başarı kriterine ulaşıncaya kadar tekrarlanır. Gradient Boosting, yanlış sınıflandırılmış örnekleri düzeltmeye yönelik bir strateji benimser ve bu sayede güçlü ve genel geçerli modeller elde edilir. Özellikle regresyon ve sınıflandırma problemlerinde başarılı bir şekilde kullanılır.

Semi-supervised ensemble classification:

Semi-supervised ensemble classification [1] veya yarı denetimli ensemble sınıflandırma, bir veri setinde hem etiketli (bilinen) hem de etiketsiz (bilinmeyen) veri örneklerini içeren bir sınıflandırma yaklaşımını temsil eder. Bu metot, özellikle sınıflandırma problemlerinde etiketlenmiş verinin sınırlı olduğu durumlarda kullanılır ve sınıflandırıcıların etkisini artırmayı amaçlar. Yöntem, sınıflandırıcıları etiketli veri örneklerine odaklanmak yerine genel bilgi çıkarımına yönlendirerek, özellikle az sayıda etiket bulunan durumlarda daha etkili ve genelleştirilebilir modeller oluşturmaya hedefler.

Etiketli Veri Kullanımı: İlk olarak, etiketli veri örnekleri üzerinde bir temel sınıflandırıcı veya sınıflandırıcılar eğitilir.

Etiketsiz Veri Kullanımı: Daha sonra, etiketsiz veri örnekleri üzerinde bir sınıflandırıcı veya sınıflandırıcılar eğitilir. Etiketsiz veriler, sınıflandırıcıların genel bilgi edinmelerine yardımcı olabilir.

Ensemble Oluşturma: Etiketli ve etiketsiz veriler üzerinde eğitilen sınıflandırıcılar bir araya getirilerek bir ensemble oluşturulur. Bu ensemble, her bir sınıflandırıcının güçlü yanlarını birleştirerek daha güçlü ve genel geçerli bir sınıflandırıcı elde etmeyi hedefler.

Semi-supervised ensemble classification [8] özellikle sınırlı etiketli veri durumlarında önemli bir avantaj sunmaktadır. Bu yaklaşım, sınıflandırıcıların genel bilgi edinimini artırarak model performansını belirgin bir şekilde iyileştirebilir. Ancak, etiketsiz veri kullanımının doğruluğunu artırmak ve overfitting'i önlemek için dikkatli bir şekilde yönetilmesi gereken bir süreçtir. Özellikle veri setindeki etiketsiz örneklerin kalitesi, bu yaklaşımın başarısını belirlemede kritik bir rol oynar. Bu nedenle, etiketsiz veri örneklerinin doğru bir şekilde seçilmesi ve entegrasyonu, modelin güvenilirliğini ve genel performansını önemli ölçüde etkiler. Yeterli dikkat gösterildiğinde, yarı

denetimli ensemble sınıflandırma, sınıflandırma performansını artırmak ve genel model stabilitesini güçlendirmek için etkili bir strateji sunabilir.

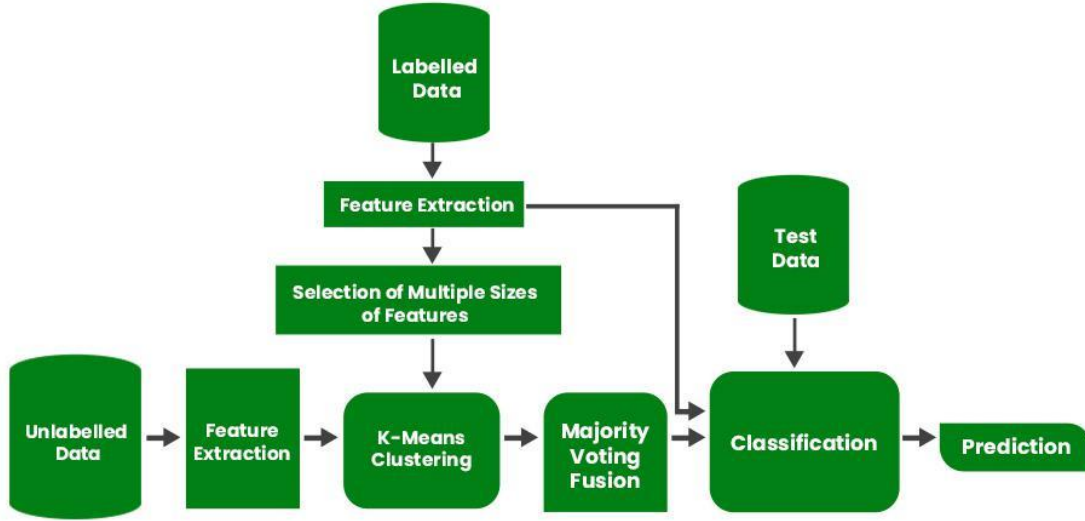


Figure 3 Semi-Supervised Learning in ML

Clustering ensemble:

Clustering ensemble [9], çeşitli kümeleme algoritmalarını entegre ederek farklı kümeleme bölümleri oluşturur ve bu bölümleri birleştirerek ortak bir çözüm elde etmeyi amaçlar. Clustering topluluğu yöntemleri, her bir kümeleme üyesinden gelen bilgileri etkili bir şekilde bir araya getirerek tek başına kullanılan kümeleme algoritmalarına kıyasla daha yüksek doğruluk, sağlamlık ve kararlılık sunma eğilimindedir. Bu metodoloji, farklı kümeleme algoritmalarının güçlü yönlerini birleştirerek daha güvenilir ve genel geçer bir çözüm elde etmeyi hedefler, bu da karmaşık veri setlerinde daha iyi performans sağlar.

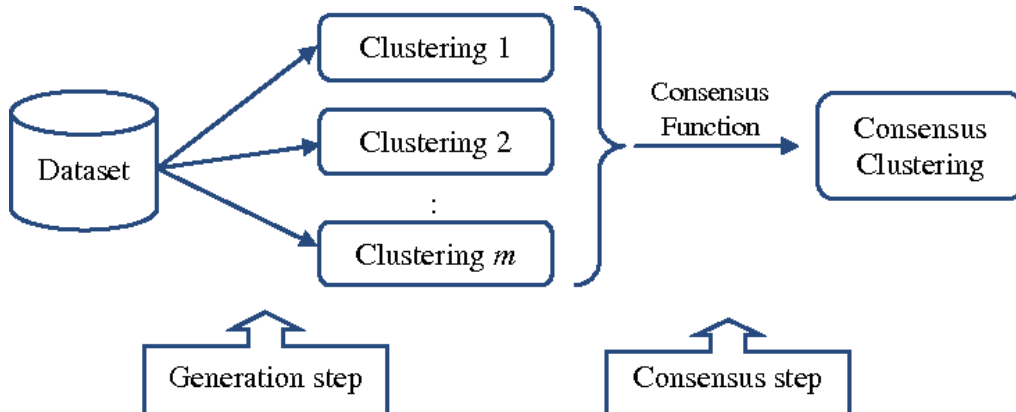


Figure 4 Clustering ensemble learning genel sürecinin diyagramı.

Figure 4'te (A SURVEY OF CLUSTERING ENSEMBLE ALGORITHMS SANDRO VEGA PONS and JOSÉ RUIZ-SHULCLOPER y Advanced Technologies Application Center) clustering ensemble öğrenmesine genel bir bakış atılmıştır.

Semi-supervised clustering ensemble:

Semi-supervised clustering ensemble learning [10], kümeleme topluluğu sürecini yönlendirmek için bağlanamaz ve bağlanmalı ön bilgileri kullanarak gelişmiş bir yaklaşım sunar. Bu yöntem, hem örnek verilerden hem de etiketli verilerden yararlanarak model performansını artırmaya odaklanır. Kümeleme ve topluluk öğrenmesinin bir kombinasyonu olan yarı denetimli kümeleme topluluğu, geleneksel kümeleme yöntemlerine göre daha kesin ve güvenilir sonuçlar elde etme potansiyeli taşır.

Bu yaklaşım, kümeleme ve topluluk öğrenme disiplinlerinin avantajlarını birleştirerek model doğruluğunu artırır. Özellikle, yarı denetimli kümeleme topluluğu alanındaki çalışmalar, kümeleme üyelerinin üretim ve seçim süreçlerini optimize etmeye odaklanmaktadır. Bu çabalar, kümeleme algoritmalarının veriye daha iyi adapte olmasını ve etiketli örnekleri daha verimli bir şekilde kullanmasını hedefler. Sonuç olarak, yarı denetimli kümeleme topluluğu, karmaşık veri setlerinde etkili ve genel geçer bir kümeleme sağlama amacıyla önemli bir araştırma ve geliştirme alanı sunmaktadır.

Wei ve diğerleri [11], sınıf etiketleri ve ikili kısıtlamalar da dahil olmak üzere ön bilgileri kullanarak temel kümeleme bölümleri oluşturan bir hibrit yarı denetimli kümeleme topluluğu algoritması önerdiler. Bu bölümlere dayanarak, özellik çıkarımları için uzamsal dağılımı dikkate alan bir metrik fonksiyon tasarlandı ve daha sonra bir konsensüs fonksiyonuna entegre edildi. Bu önerilen yöntem, hem sınıf etiketlerini hem de önceden bilinen kısıtlamaları kullanarak kümeleme performansını artırmayı amaçlamaktadır.

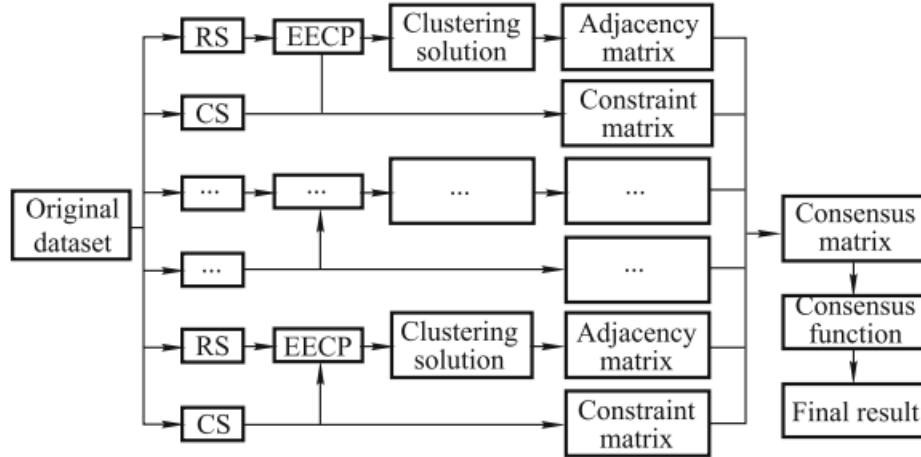


Figure 5 Semi-supervised clustering ensemble learning modelinin diyagramı

Figure 5'te (Zhiwen YU , Xibin DONG, Wenming CAO, Yifan SHI, Qianli MA, "A survey on ensemble learning" 10. sayfa) semi-supervised clustering ensemble learning'in arttırımlı modeli görülmektedir.

Semi-supervised clustering ensemble learning içinde, arttırımlı model (incremental model) genellikle sürekli olarak gelen yeni verilere adapte olabilen bir modeli ifade eder. Bu tür bir model, yeni etiketlenmiş veya etiketlenmemiş verilerle eğitilebilir ve kümeleme sürecine bu güncel bilgileri dahil edebilir.

Arttırımlı modeller, veri setinin zaman içinde değiştiği veya genişlediği durumlarda faydalı olabilir. Yeni veriler geldikçe model, bu verileri kullanarak daha genel ve güncel bir anlayış geliştirebilir. Arttırımlı modeller, öğrenme sürecini güncel tutarak, kümeleme sonuçlarını zaman içinde iyileştirebilir ve daha dinamik veri setleriyle başa çıkabilir.

FACIAL ACTION CODING SYSTEM VE ACTION UNITS

Yüz ifadelerinden duygu tanımlama için en bilindik iki tür yaklaşım vardır: Convolutional Neural Networks(CNN) ve Facial Action Coding System(FACS). CNN tarzı yaklaşım bir önceki raporumuzda anlatılmıştı. CNN bir model kenarlar, dokular ve desenleri öğrenmede başarı gösterir. FACS ise doğrudan kas-mimik hareketleriyle ilgilenecek duygular hakkında daha detaylı bilgi verebilir. Yüz Eylem Kodlama Sistemi (FACS) bir dizi eylem birimi (AU) tarafından verilmektedir. Her bir AU, tipik olarak yüzdeki duygu ifadelerini üretirken görülen bireysel veya kas gruplarının temel eylemlerini kodlar. Örneğin, AU 4 kaşların indirilmesiyle sonuçlanan iki kasın kasılmasını tanımlar. Bu AU tipik olarak üzüntü, korku ve öfke ifadelerinde görülür[12]. Fakat uygulanması CNN'e göre daha karmaşıktır ve ön adımlar gerektirebilir. Bu bölümde FACS'e dayalı çalışmalar incelenmiştir.

AU bazlı çalışmaların bazıları sadece basit 6 duyguyu(korku, mutluluk, şaşkınlık vb.) tanıyan modeller geliştirirken bazılarında birleşik duygular da(şaşkın-mutlu, üzgün-korkmuş vs.) hesaba katılmıştır. Du, Tao ve Martinez [12]'in yazdığı makalede basit 6 duygu da dahil olmak üzere 22 farklı duygu FACS kodlanmıştır. Sonuçlar için bir tablo hazırlanıp aktif kullanılan AU'lar, bütün duygularda kullanılmayan AU'lar listelenmiştir. Çalışma birleşik duyguların farklı ama yine de temsil ettikleri alt kategorileri ile tutarlı olduğunu göstermiştir. Örneğin, mutlu bir şekilde şaşkın ifadesi mutlu ve şaşkın kategorilerindeki AU'ları içerir ama sadece bunlardan oluşmaz[13]. J.Jiang vd.[13] bu çalışmadan yola çıkarak BC-FER çalışmasını geliştirmiştir. Keskin etiketler BC-FER'in performansını kısıtlatacağı için keskin etiketleri kullanarak yumuşak etiketleri elde ettikleri ESLM(Expression Soft Label Mining) metodunu ortaya atmışlardır. ESLM, tekrarlanan yumuşak etiket madenciliği (ISLM) ve ifade korelasyon puanı öğrenme(ECSL) kaybı olmak üzere iki kısımdan oluşur. ISLM, modeli otomatik olarak öğrenerek yumuşak etiket üretmeye yarayan öz bilgi damıtma[14] fikrine dayanır. ECSL kaybından ise ağırlık çıktılarını regularize etmek için faydalanılmıştır. ECSL, duygular arasındaki korelasyonu yakalar ve daha anlamlı hedefler sağlayabilmek için ISLM ile çalışır [13]. Bahsedilen ISLM ve ECSL'in çalışmaları Şekil.1 ve Şekil.2'de verilmiştir.

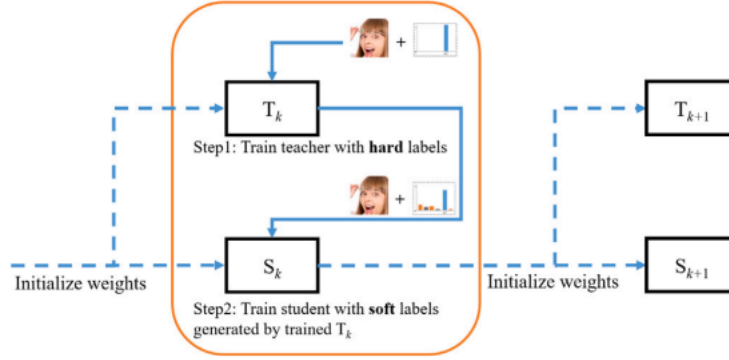


Fig. 2. The overview of proposed ISLM. T_k and S_k represent teacher and student model at the k th mining round.

Şekil.1 – Kaynak: [13]



Fig. 3. The outline of proposed ECSL. The correlated class group shares at least one common basic expression component with the target class. The uncorrelated class group contains no common component with target class. We expect the softmax score of correlated classes to be much larger than that of uncorrelated classes.

Şekil.2 – Kaynak: [13]

Liu vd. [15] çalışmasında ise görünüm bazlı metodlar ile AU bazlı metodları birleştirerek bir Mikro-Eylem-Deseni(MAP) önermiştir. Görünüm bazlı metodlar yüksek seviyedeki ifadeleri, düşük seviyedeki özelliklerden öğrenirken semantik boşluğa takılır. AU bazlı metodlarda ise resimlerden kasların eylemlerini tespit etmek zordur. AU'ların prensibinden yararlanılarak; kaş çatma, sırtma gibi yüzdeki kas hareketlerinin neden olduğu yerel görünüm değişikliklerini yakalayarak veriyi öğrenen MAP konsepti aynı zamanda daha yüksek-seviyeli kavramları simüle edilebilmek için MAP gruplar halinde birleştirilebilir. Her bir MAP grubu, bitişik katmanlar arasında ağ bağlantılarını belirlemek için bir sonraki katmandaki belirli bir birimin alıcı alanını oluşturur. Her bir alıcı alan, kademeli olarak daha üst düzey özellikleri öğrenmek için grup bazında bir alt ağ oluşturan çok katmanlı bir öğrenme süreci de kullanmaktadır. Önerilen yöntem Şekil.3'te

verilmiştir. Burada üç ardışık modül bulunmaktadır: MAP temsili öğrenimi alıcı alan inşası ve grup bazlı alt ağ öğrenimi. Öğrenilen derin mimari yüz AU'larının yorumlanmasından esinlenen hiyerarşik bir özellik öğrenme işlemini gerçekleştirdiğinden buna, AU'dan Esinlenilmiş Derin Ağlar (AUDN) adı verilmiştir.

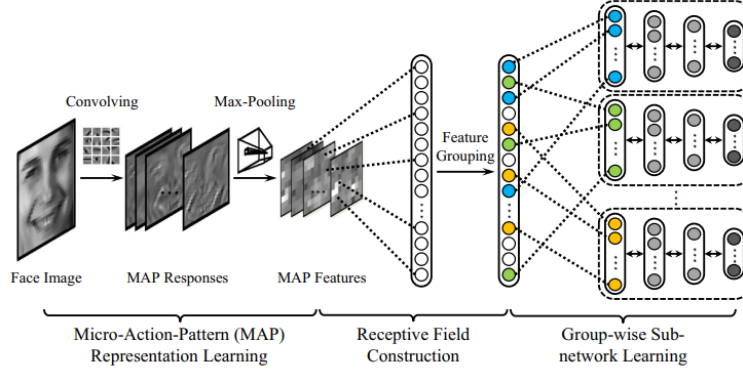


Fig. 1. The pipeline of the proposed method. There are three sequential modules, i.e. Micro-Action-Pattern (MAP) representation learning, receptive field construction, and group-wise sub-network learning.

Şekil.3 – Kaynak: [15]

Sonuç olarak kendi yüzden duygu tanıma çalışmamızda hem CNN hem de FACS'tan oluşan hibrit bir model oluşturarak birleşik-duyguları tanımayı amaçlıyoruz. Çalışmamızın birleşik duyguları tanınması için Soft Label Mining metodunu kullanmayı düşünebiliriz. Daha doğru performans için Cai vd. ortaya attığı MTCNN mimarisini yüz tanıma aracı olarak kullanabiliriz [16]. Bu modelleri birleştirmek için ensemble metotları kullanmayı hedefliyoruz.

EMOTION STRUCTURING

Veri Toplama ve Hazırlık:

Spotify API'si kullanılarak kullanıcıların dinleme geçmişi, favori şarkılar, tekrarlanan parçalar gibi veriler toplanacak.

Duygu durumu etiketlenmiş veri setleri aracılığıyla duygu analizi için veri toplanabilir (örneğin, "Million Song Dataset", Last.fm verileri). Ayrıca, duygu tanıma için yüz ifadesi veri setleri (örneğin, CK+, FER-2013) kullanılabilir. [17] [18]

Spotify'dan alınan veriler, müzik özellikleri (tempo, tonalite, akustiklik, dans edilebilirlik gibi) açısından işlenecek ve özellik mühendisliği sürecinden geçirilecek.

Spotify, kullanıcıların müzik dinleme alışkanlıklarını kaydeden zengin bir veri havuzuna sahiptir. API'leri aracılığıyla kullanıcıların dinleme geçmişi, favori şarkılar, çalma listeleri ve tercihleri gibi veriler elde edilebilir.

Müzik özellikleri (tempo, dans edilebilirlik, enerji, valence gibi) her şarkı için mevcut olan veriler arasındadır.

Spotify API Kullanımı:

API, HTTP istekleriyle müzik verilerine erişim sağlar. Örneğin, kullanıcıların çalma listeleri, şarkı özellikleri, sanatçı bilgileri gibi verilere erişmek mümkündür.

API, OAuth 2.0 kimlik doğrulama protokolünü kullanarak yetkilendirme sağlar ve RESTful metodolojiye uygun olarak veri sağlar.

Müzik Özellikleri ve Analiz:

Spotify, her şarkı için çeşitli özellikler sunar. Örneğin, "tempo" şarkının hızını, "valence" şarkının ne kadar pozitif bir duygu taşıdığını ifade eder. [21]

Spotify for Developers platformunda sunulan API'ler, müzik özelliklerine ve analizine (örneğin, audio analysis API) erişimi kolaylaştırır.

Veri analizi için müzik özellikleri, öneri sistemleri oluşturulurken kullanılabilir. Özellikle, kullanıcıların dinleme tercihlerine uygun şarkıları önermek için önemlidir.

Spotify API Örnekleri:

Örneğin, GET /v1/me/top/artists kullanıcının en çok dinlediği sanatçıları listeler.

GET /v1/recommendations kullanıcının dinleme geçmişi ve tercihlerine göre öneriler sunar.

Duygu Durumu ve Yüz Tanıma Modelleri:

Duygu Durumu:

Duygu analizi için derin öğrenme yöntemleri kullanılacak. Önceden eğitilmiş mimariler (örneğin, VGG, ResNet, veya EfficientNet gibi) transfer learning ile duygu sınıflandırması için uyarlanabilir. [19]

Ensemble yöntemleri (Random Forest, Gradient Boosting gibi) kullanılarak farklı model sonuçları birleştirilebilir. [19]

Yüz Tanıma:

Yüz tanıma için önceden eğitilmiş modeller (örneğin, VGGFace, OpenCV'nin yüz tanıma algoritmaları) transfer learning veya fine-tuning ile kullanılabilir.

Yüz ifadeleri, duygu durumu analizi için öznitelik çıkarımı amacıyla kullanılacak.

Öneri Sistemi Oluşturma:

Kullanıcıların dinleme geçmişi, duygu durumu analizi sonuçları ve belirli duygulara uygun müzikler üzerinden, derin öğrenme tabanlı öneri sistemleri geliştirilecek.

Karma duygulara yönelik özel öneriler, farklı duygu kombinasyonları için öneri algoritması tarafından üretilecek.

Model Değerlendirme ve İyileştirme:

Modeller, duygu sınıflandırma doğruluğu, yüz tanıma performansı ve öneri sistemlerinin başarımı açısından kapsamlı şekilde değerlendirilecek.

Cross-validation, hiperparametre ayarlamaları ve farklı model mimarilerinin performans karşılaştırmalarıyla modeller iyileştirilecek. [20]

Kullanıcı geri bildirimleri ve model performansındaki değişiklikler, sürekli iyileştirme sürecinde dikkate alınacak.

Referanslar

- [1] X. Dong, Z. Yu, W. Cao, Y. Shi, and Q. Ma, “A survey on ensemble learning,” *Frontiers of Computer Science*
- [2] Zhiwen YU , Xibin DONG, Wenming CAO, Yifan SHI, Qianli MA, “A survey on ensemble learning“
- [3] Breiman L. Bagging predictors. *Machine Learning*, 1996, 24(2): 123– 140
- [4] Hastie T, Rosset S, Zhu J, Zou H. Multi-class adaboost. *Statistics and its Interface*, 2009, 2(3): 349–360
- [5] Breiman L. Random forests. *Machine Learning*, 2001, 45(1): 5–32
- [6] Ho T K. Random decision forests. In: *Proceedings of the 3rd International Conference on Document Analysis and Recognition*. 1995, 278–282
- [7] Friedman J H. Stochastic gradient boosting. *Computational Statistics and Data Analysis*, 2002, 38(4): 367–378
- [8] geeksforgeeks Semi-Supervised Learning in ML
- [9] A SURVEY OF CLUSTERING ENSEMBLE ALGORITHMS SANDRO VEGA PONS and JOSÉRUIZ-SHULCLOPER y Advanced Technologies Application Center
- [10] Yu Z, Kuang Z, Liu J, Chen H, Zhang J, You J, Wong H S, Han G. Adaptive ensembling of semi-supervised clustering solutions. *IEEE Transactions on Knowledge and Data Engineering*, 2017

- [11] Wei S, Li Z, Zhang C. Combined constraint-based with metric-based in semi-supervised clustering ensemble. International Journal of Machine Learning and Cybernetics, 2018
- [12] Shichuan Du, Yong Tao, and Aleix M. Martinez(2014) - Compound Facial Expressions of Emotion
- [13] Jinh Jiang, Mei Wang, Bo Xiao, Jiani Hu, Weihong Deng(2023) - Joint Recognition of Basic and Compound Facial Expressions by Mining Latent Soft Labels
- [14] K. Kim, B. Ji D. Yoon, S. Hwang(2021) - Self-knowledge Distillation with Progressive Refinement of Targets
- [15] Mengyi Liu, Shaoxin Li, Shiguang Shan, Xilin Chen(2015) – AU-Inspired Deep Networks for Facial Expression Feature Learning
- [16] Zhenni Chai, Qingshan Liu, Shanmin Wang, Bruce Yang(2018) – Joint Head Pose Estimation with Multi-task Cascaded Convolutional Networks for Face Aligment
- [17] Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. (2009). Imagenet: A large-scale hierarchical image database. 2009 IEEE conference on computer vision and pattern recognition.
- [18] Khorrami, P., & LeCun, Y. (2015). Deep convolutional neural networks for image classification: A comprehensive review. CoRR, abs/1510.07493.
- [19] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- [20] Breiman, L. (2001). Random forests. Machine learning, 45(1), 5-32.
- [21] Bell, R. M., Koren, Y., & Volinsky, C. (2007). The BellKor solution to the Netflix prize. Netflix Prize Documentation.
- [22] Lamere, P., & Eck, D. (2011). Challenges in Building Large-Scale Information Retrieval and Recommendation Systems at Spotify. Proceedings of the Fifth ACM Conference on Recommender Systems.